

Wykrywanie nadużyć w służbie zdrowia

Zofia Dekowska

6 maja 2026

Spis treści

1	Wstęp i identyfikacja problemu	2
1.1	Typ zadania Machine Learning	2
1.2	Specyfika problemu	2
1.3	Cel biznesowy i analityczny	2
2	Wybór i uzasadnienie zbioru danych	2
2.1	Charakterystyka źródła danych	2
2.2	Struktura i opis cech zbioru	2
2.3	Uzasadnienie wyboru zbioru	3
3	Wybór i uzasadnienie miar jakości	3
3.1	Uzasadnienie biznesowe prognozy decyzyjnego	4
4	Projekt walidacji i sposób weryfikacji modelu	4
4.1	Podział zbioru danych (Hold-out Validation)	4
4.2	Zastosowane techniki weryfikacji	4
5	Dobór hiperparametrów i zapobieganie przeuczeniu	5
5.1	Kluczowe hiperparametry i ich uzasadnienie	5
5.2	Mechanizmy zapobiegania przeuczeniu (Regularization)	5
6	Przeprowadzenie badania	6
6.1	Wstępna selekcja i porównanie modeli	6
6.2	Wyniki modelu Random Forest (Baseline)	6
6.3	Wykorzystanie modelu XGBoost i analiza wyników	8
6.4	Weryfikacja za pomocą macierzy pomyłek	9
6.5	Analiza krzywej Precision-Recall	10
6.6	Analiza ważności cech (Feature Importance)	10
7	Podsumowanie i wnioski	11
7.1	Ocena poprawności i interpretacja rezultatów	12
7.2	Ograniczenia modelu	12
7.3	Dalsze kierunki rozwoju	12
7.4	Konkluzja	12

1 Wstęp i identyfikacja problemu

1.1 Typ zadania Machine Learning

Problem detekcji oszustw w roszczeniach medycznych został zdefiniowany jako zadanie klasyfikacji binarnej. Celem modelu jest przypisanie każdego roszczenia do jednej z dwóch rozłącznych klas:

- **Klasa 0 (Negative):** Roszczenie uczciwe, zgodne z procedurami.
- **Klasa 1 (Positive):** Roszczenie noszące znamiona oszustwa lub nadużycia.

1.2 Specyfika problemu

Kluczową cechą zidentyfikowanego zadania jest silne **niezbalansowanie zbioru danych**. W rzeczywistych systemach medycznych oszustwa stanowią niewielki odsetek wszystkich transakcji (w badanym zbiorze jest to ok. 8.3%).

Z punktu widzenia uczenia maszynowego, jest to trudniejsze zadanie od klasycznej klasyfikacji, ponieważ model mógłby ignorować klasę mniejszościową. W związku z tym, problem ten wymaga zastosowania specyficznych algorytmów oraz miar jakości skupionych na klasie pozytywnej.

1.3 Cel biznesowy i analityczny

Głównym celem jest stworzenie narzędzia wspomagającego analityków ds. nadużyć w służbie zdrowia. Priorytetem jest wysoka **czułość**, aby zminimalizować ryzyko finansowe związane z niewykrytymi oszustwami, przy jednoczesnym zachowaniu akceptowalnego poziomu **precyzji**, aby nie przeciążyć działu weryfikacji fałszywymi alarmami.

2 Wybór i uzasadnienie zbioru danych

2.1 Charakterystyka źródła danych

W badaniu wykorzystano zbiór danych *Healthcare Fraud Detection Dataset* pochodzący ze strony Kaggle [1]. Zbiór ten zawiera szczegółowe rekordy dotyczące roszczeń medycznych, obejmujące informacje o pacjentach, procedurach oraz podmiotach świadczących usługi. Dane te odzwierciedlają rzeczywiste scenariusze operacyjne w systemach ubezpieczeń zdrowotnych, co czyni je reprezentatywnym materiałem do budowy systemów typu *fraud detection*.

2.2 Struktura i opis cech zbioru

Wykorzystany zbiór danych charakteryzuje się dużą wielowymiarowością, co pozwala na wieloaspektową analizę zachowań o charakterze oszukańczym. Cechy zostały pogrupowane w pięć kluczowych kategorii:

- **Informacje finansowe i roszczeniowe:** Kluczowe zmienne numeryczne *Claim_Amount* oraz *Approved_Amount*. Dodatkowo uwzględniono status roszczenia (*approved*, *rejected*, *pending*) oraz typ ubezpieczenia (*private*, *Medicare*, *Medicaid*, *self-pay*).

- **Dane o pacjencie:** Profil demograficzny (wiek, płeć, lokalizacja na poziomie stanu) wzbogacony o historię medyczną, w tym wskaźnik chorób przewlekłych (*chronic condition indicator*) oraz liczbę wizyt w ciągu ostatnich 12 miesięcy. Pozwala to modelowi na identyfikację pacjentów o nietypowej aktywności.
- **Dane o dostawcach usług:** Unikalne identyfikatory oraz specjalizacje (np. kardiologia, ortopedia). Istotną cechą jest miesięczny wolumen roszczeń (*Monthly claim volume*), który pozwala wykrywać nienaturalnie wysoką aktywność rozliczeniową w stosunku do średniej.
- **Kodowanie medyczne:** Zastosowanie standardów ICD-10 (diagnozy) oraz CPT (procedury). Zbiór uwzględnia logiczne powiązania między postawioną diagnozą a wykonaną procedurą, co jest fundamentem wykrywania zawyżania kodu procedury medycznej.
- **Atrybuty czasowe i logistyczne:** Cechy określające czas między wykonaniem usługi a złożeniem wniosku (*Days_Between_Service_and_Claim*), typ wizyty (*outpatient, inpatient, emergency*) oraz długość hospitalizacji (*Length of stay*).

2.3 Uzasadnienie wyboru zbioru

Wybór tego konkretnego zbioru danych podyktowany był następującymi czynnikami:

1. **Realizm problemu:** Dane zawierają naturalnie występujące braki (*missing values*) oraz wymagają zaawansowanego preprocessingu (np. kodowanie cech tekstowych), co pozwala na weryfikację modelu w warunkach zbliżonych do rzeczywistych.
2. **Niezbalansowanie klas:** Według szacunków NHCAA [2], nadużycia generują straty na poziomie od 3% do nawet 10% całkowitego budżetu ochrony zdrowia, co czyni udział 8% w badanym zbiorze danymi wysoce reprezentatywnymi.
3. **Złożoność relacji:** Dane pozwalają na analizę nie tylko prostych kwot, ale również zależności między pacjentem, typem procedury a zachowaniem dostawcy usług.

3 Wybór i uzasadnienie miar jakości

W problematyce detekcji oszustw medycznych dobór metryk jest determinowany przez silne niezbalansowanie klas oraz asymetrię kosztów błędów. Ze względu na to, że klasa pozytywna (oszustwa) stanowi jedynie ok. 8% zbioru, standardowa miara *dokładność* (accuracy) jest niewystarczająca – model klasyfikujący wszystkie przypadki jako uczciwe, osiągnąłby wysoką dokładność (92%), będąc całkowicie bezużytecznym z biznesowego punktu widzenia.

W związku z powyższym, do oceny modelu wybrano zestaw metryk skupionych na zdolnościach dyskryminacyjnych algorytmu względem klasy mniejszościowej:

- **Czułość (Recall):** Jest to priorytetowa metryka w tym badaniu. Określa ona zdolność modelu do wykrywania faktycznych oszustw. Wysoka czułość oznacza, że system minimalizuje liczbę błędów II rodzaju (*False Negatives*), czyli sytuacji, w których nadużycie finansowe pozostaje niewykryte przez system kontroli.

- **Precyzja (Precision):** Informuje o tym, jaka część wskazań modelu jako oszustwo faktycznie nimi była. Wysoka precyzja pozwala ograniczyć liczbę błędów I rodzaju (*False Positives*), co przekłada się na mniejszą liczbę bezpodstawnych dochodzeń i optymalizację czasu pracy analityków weryfikujących zgłoszenia.
- **F1-Score:** Jako średnia harmoniczna precyzji i czułości, stanowi syntetyczny wskaźnik balansu modelu. Jest to miara szczególnie użyteczna przy porównywaniu różnych algorytmów (np. Random Forest vs XGBoost).
- **Krzywa Precision-Recall (PRC) oraz Area Under PRC (AUPRC):** Wybrano tę miarę zamiast standardowej krzywej ROC, ponieważ AUPRC lepiej odzwierciedla skuteczność klasyfikatora w warunkach dużej dysproporcji klas, kładąc większy nacisk na wydajność modelu w obszarze klasy pozytywnej.

3.1 Uzasadnienie biznesowe progu decyzyjnego

W analizie przyjęto założenie, że koszt niewykrytego oszustwa (strata finansowa ubezpieczyciela) jest znacznie wyższy niż koszt błędnej weryfikacji uczciwego roszczenia (koszt pracy analityka). W związku z tym, w ostatecznej implementacji modelu XGBoost, zdecydowano się na obniżenie progu decyzyjnego (*threshold*) do poziomu **0.3**, co pozwoliło na maksymalizację czułości (*Recall*) przy zachowaniu akceptowalnego poziomu precyzji.

4 Projekt walidacji i sposób weryfikacji modelu

Kluczowym elementem oceny skuteczności modelu jest zapewnienie jego zdolności do generalizacji, czyli poprawnej klasyfikacji danych, których algorytm nie widział w procesie uczenia. W niniejszym projekcie przyjęto rygorystyczny protokół walidacyjny oparty na podziale zbioru danych oraz technikach przeciwdziałających przeuczeniu.

4.1 Podział zbioru danych (Hold-out Validation)

Zbiór danych został podzielony na dwie rozłączne części w proporcjach:

- **Zbiór treningowy (80%):** Służący do dopasowania parametrów modelu i nauki wzorców zachowań.
- **Zbiór testowy (20%):** Stanowiący niezależną próbę, wykorzystaną wyłącznie do końcowej oceny jakości predykcji.

4.2 Zastosowane techniki weryfikacji

W celu zapewnienia wiarygodności wyników wdrożono następujące mechanizmy:

1. **Stratyfikacja (Stratified Sampling):** Ze względu na rzadkie występowanie klasy pozytywnej (oszustwa), zastosowano podział warstwowy. Gwarantuje on, że proporcja oszustw w zbiorze treningowym i testowym jest identyczna i odpowiada rozkładowi w całym zbiorze (ok. 8%). Zapobiega to błędom estymacji wynikającym z losowego niedoreprezentowania klasy mniejszościowej.

2. **Powtarzalność eksperymentu:** Przyjęto stałe ziarno losowości (*random seed* = 42), co umożliwia pełną reprodukowalność procesu podziału danych oraz inicjalizacji wag modelu.
3. **Macierz pomyłek (Confusion Matrix):** Podstawowym narzędziem weryfikacji była analiza błędów I i II rodzaju bezpośrednio na zbiorze testowym, co pozwoliło na precyzyjną ocenę liczby niewykrytych nadużyć.

5 Dobór hiperparametrów i zapobieganie przeuczeniu

Wybór hiperparametrów modelu XGBoost był procesem ukierunkowanym na zbalansowanie wysokiej skuteczności wykrywania oszustw z koniecznością zachowania zdolności modelu do generalizacji. Zastosowano następującą konfigurację:

5.1 Kluczowe hiperparametry i ich uzasadnienie

- **scale_pos_weight=11:** Jest to najważniejszy parametr w kontekście niezbalansowania klas. Został on obliczony jako stosunek liczby przypadków klasy negatywnej do pozytywnej ($\frac{92\%}{8\%} \approx 11.5$). Ustawienie to wymusza na algorytmie nadanie wyższej wagi błędom popełnianym na klasie oszustw, co bezpośrednio przekłada się na wzrost metryki czułości.
- **max_depth=6:** Ograniczenie głębokości drzew do 6 poziomów pełni funkcję regularyzacyjną. Zapobiega to nadmiernemu rozbudowaniu drzew, które mogłyby zacząć opisywać specyficzne, jednostkowe przypadki (szum) zamiast ogólnych schematów nadużyć.
- **learning_rate=0.1:** Zastosowano relatywnie niski współczynnik uczenia, co wymaga od modelu budowy większej liczby drzew w sposób krokowy. Zapobiega to nadmiernemu dopasowaniu do szumu w danych i pozwala na dokładniejsze dopasowanie wag w procesie gradientowego wzmocnienia.
- **n_estimators=100:** Liczba iteracji została dobrana tak, aby zapewnić wystarczającą złożoność modelu przy zachowaniu stabilności wyników na zbiorze testowym.

5.2 Mechanizmy zapobiegania przeuczeniu (Regularization)

Poza doбором parametrów strukturalnych, proces treningu był monitorowany pod kątem *overfittingu* poprzez:

1. **Analizę różnic wydajności:** Porównanie raportów klasyfikacji dla zbioru treningowego i testowego wykazało stabilność metryk (brak drastycznego spadku precyzji na danych testowych), co potwierdza poprawną generalizację.
2. **Wbudowaną regularyzację L1/L2:** Wykorzystano natywną dla XGBoost funkcję celu `logloss`, która automatycznie nakłada kary za zbytnią złożoność wag w liściach drzew, promując prostsze i bardziej odporne modele.

3. **Strojenie progu decyzyjnego (*Thresholding*):** Zamiast zmieniać architekturę modelu w celu zwiększenia czułości, zastosowano zewnętrzny próg decyzyjny 0.3. Pozwoliło to na elastyczne sterowanie czułością bez ryzyka destabilizacji struktury drzew decyzyjnych.

6 Przeprowadzenie badania

6.1 Wstępna selekcja i porównanie modeli

W fazie koncepcyjnej rozważono trzy różne architektury algorytmów uczenia maszynowego, aby wyłonić rozwiązanie najlepiej dopasowane do specyfiki detekcji oszustw medycznych:

1. **Sztuczne Sieci Neuronowe (MLP):** Model ten został odrzucony na wstępnym etapie. Sieci neuronowe wymagają zazwyczaj znacznie większych zbiorów danych do efektywnej nauki oraz są trudne w interpretacji (tzw. *black box*), co w audycie medycznym jest wadą i eksperci muszą rozumieć, dlaczego dany przypadek został uznany za podejrzany.
2. **Random Forest (Las Losowy):** Był to pierwszy model poddany testom. Choć algorytm ten dobrze radzi sobie z klasyfikacją, w naszych testach wykazywał tendencję do **przeuczenia** (*overfitting*). Model osiągał lepsze wyniki na zbiorze treningowym, jego skuteczność na danych testowych spadała (szczególnie w zakresie precyzji dla klasy pozytywnej).
3. **XGBoost (Extreme Gradient Boosting):** Ostatecznie wybrany jako model bazowy. Wykazał się najlepszą zdolnością do generalizacji oraz, dzięki parametrowi *scale_pos_weight*, pozwolił na najskuteczniejsze opanowanie problemu niezbalansowania klas.

6.2 Wyniki modelu Random Forest (Baseline)

W pierwszej fazie eksperymentów przetestowano model Random Forest. Uzyskane wyniki (Tabela 1) ujawniły charakterystyczne wyzwanie związane z tym algorytmem w kontekście detekcji anomalii.


Zbiór danych	Klasa	Precyzja (Precision)	Czułość (Recall)	F1-Score
Treningowy	1 (Oszustwa)	0.59	1.00	0.74
Testowy	1 (Oszustwa)	0.52	0.98	0.68

Tabela 1: Metryki modelu Random Forest.

W analizie modelu Random Forest skoncentrowano się wyłącznie na wynikach dla klasy pozytywnej (1 - Oszustwa), ponieważ celem etapu baseline było określenie bazowej zdolności algorytmu do identyfikacji anomalii w warunkach silnego niezbalansowania klas.

Interpretacja ważności cech (Random Forest)

Analiza hierarchii ważności cech dla modelu Random Forest (Rysunek 1) pozwala na identyfikację kluczowych zmiennych determinujących decyzje klasyfikacyjne tego algorytmu:



Rysunek 1: Ranking najważniejszych cech modelu Random Forest.

- **Dominacja aspektu czasowego:** Cecha `Days_Between_Service_and_Claim` uzyskała najwyższy wynik istotności, co wskazuje, że dla tego modelu kluczowym sygnałem ostrzegawczym jest czas, jaki upłynął między wykonaniem usługi medycznej a momentem zgłoszenia roszczenia.
- **Status roszczenia jako indykator:** Wysoka pozycja cechy `Claim_Status_Approved` sugeruje, że algorytm silnie wiąże fakt wcześniejszej akceptacji wniosku z prawdopodobieństwem wystąpienia nadużycia, co może jednak prowadzić do utrwalania historycznych schematów zamiast wykrywania nowych anomalii.
- **Rola parametrów finansowych:** Zmienne `Claim_Amount` oraz `Approved_Amount` stanowią istotny komponent decyzyjny, co potwierdza, że model poprawnie identyfikuje zależność między wysoką wartością roszczenia a ryzykiem oszustwa.
- **Cechy drugorzędne:** Pozostałe zmienne, takie jak dane demograficzne (`Patient_Age`) czy logistyczne (`Claim_Submission_Day`), mają znikomy wpływ na

wynik modelu, co sugeruje, że Random Forest koncentruje się na wąskiej grupie najbardziej jaskrawych wskaźników.

Wnioski z testów Random Forest

- **Nadmierna liczba fałszywych alarmów:** Precyzja na poziomie 0.52 na zbiorze testowym oznacza, że niemal połowa wskazań modelu to błędy I rodzaju. Z perspektywy operacyjnej jest to wynik nieefektywny, gdyż generuje zbyt duże obciążenie dla zespołu weryfikującego roszczenia.
- **Stabilność Recall:** Model bardzo dobrze radzi sobie z wyłapywaniem oszustw (0.98), jednak robi to "kosztem wszystkiego", klasyfikując zbyt wiele uczciwych roszczeń jako podejrzone.
- **Decyzja o zmianie modelu:** Uzyskane wyniki stały się bezpośrednią motywacją do zastosowania algorytmu **XGBoost**. Pozwolił on, dzięki precyzyjnemu ważeniu klas (`scale_pos_weight`) i optymalizacji progu decyzyjnego, na podniesienie precyzji przy zachowaniu wysokiej czułości, co czyni system znacznie bardziej użytecznym w praktyce.

6.3 Wykorzystanie modelu XGBoost i analiza wyników

Badanie przeprowadzono zgodnie z opisaną wcześniej metodyką, koncentrując się na zdolności modelu do poprawnej identyfikacji przypadków nadużyć ($Is_Fraud = 1$). Głównym eksperymentem była weryfikacja skuteczności algorytmu XGBoost po optymalizacji wag klas i dostrojeniu progu decyzyjnego.

Optymalizacja progu decyzyjnego

Standardowy próg decyzyjny (0.5) został uznany za zbyt konserwatywny, co skutkowało pomijaniem znaczącej liczby nadużyć. Ustalono ostatecznie próg na poziomie **0.3**. Pozwoliło to na przesunięcie balansu modelu w stronę wyższej czułości, co jest kluczowe w systemach bezpieczeństwa finansowego.

Analiza wyników klasyfikacji

Poniżej przedstawiono szczegółowe wyniki klasyfikacji dla modelu finalnego. Porównanie wyników na obu zbiorach potwierdza, że model nie uległ przeuczeniu i zachowuje wysoką skuteczność na nowych danych.

Zbiór danych	Klasa	Precyzja (Precision)	Czułość (Recall)	F1-Score
Treningowy	0 (Uczciwe)	1.00	0.99	1.00
	1 (Oszustwa)	0.93	1.00	0.97
Testowy	0 (Uczciwe)	1.00	0.98	0.99
	1 (Oszustwa)	0.82	0.97	0.89

Tabela 2: Metryki klasyfikacji modelu XGBoost dla zbioru treningowego i testowego.

Prezentowane w Tabeli 2 wartości precyzji i czułości są obliczane osobno dla każdego z wierszy, przyjmując daną klasę jako punkt odniesienia. Przykładowo, precyzja dla


klasy "Oszustwa" mierzy wiarygodność alarmów modelu, natomiast precyzja dla klasy "Uczciwe" określa pewność systemu co do braku nadużyć w danym rozszczeniu.

Kluczowe spostrzeżenia:

- **Wysoka skuteczność detekcji:** Czułość na poziomie 0.97 na zbiorze testowym oznacza, że model pomija jedynie 3% faktycznych oszustw.
- **Optymalizacja precyzji:** W porównaniu do modelu Random Forest (gdzie precyzja wynosiła 0.52), XGBoost uzyskał wynik 0.82. Oznacza to drastyczną redukcję liczby fałszywych alarmów przy zachowaniu niemal identycznej czułości.
- **Generalizacja:** Różnica między F1-score na zbiorze treningowym (0.97) a testowym (0.89) jest relatywnie mała, co świadczy o stabilności modelu i poprawnym doborze parametrów regularizacyjnych.

6.4 Weryfikacja za pomocą macierzy pomyłek


Analiza macierzy pomyłek (Rysunek 2) potwierdza wysoką skuteczność modelu. Zidentyfikowano 161 przypadków *True Positives* przy jedynie 5 przypadkach *False Negatives* (oszustwa pominięte). Liczba błędnych alarmów (*False Positives*) wyniosła 35, co przy skali 1799 poprawnie sklasyfikowanych uczciwych rozszczeń świadczy o wysokiej stabilności algorytmu.



Rysunek 2: Macierz pomyłek dla modelu XGBoost.

6.5 Analiza krzywej Precision-Recall


Zastosowany wskaźnik **Average Precision (AP = 0.99)** wskazuje na niemal idealną separację klas. Krzywa Precision-Recall utrzymuje się blisko górnej krawędzi wykresu, co dowodzi, że model potrafi utrzymać bardzo wysoką precyzję nawet przy ekstremalnie wysokich poziomach czułości.



Rysunek 3: Krzywa Precision-Recall dla modelu XGBoost.

6.6 Analiza ważności cech (Feature Importance)

W celu zrozumienia czynników determinujących decyzje modelu, przeprowadzono analizę ważności cech (Rysunek 4). Algorytm XGBoost pozwala na precyzyjne określenie, które zmienne miały największy wpływ na redukcję błędu podczas budowania drzew decyzyjnych.



Rysunek 4: Ranking najważniejszych cech modelu XGBoost.

Interpretacja wyników:

- **Dominacja czynników finansowych:** Zmienne takie jak `Claim_Amount` oraz `Approved_Amount` zajmują czołowe miejsca w rankingu. Potwierdza to intuicję biznesową, że kwoty roszczeń są najbardziej jaskrawym indykatorem potencjalnych nadużyć.
- **Znaczenie cech czasowych:** Wysoka pozycja cechy `Days_Between_Service_and_Claim` sugeruje, że opóźnienia w raportowaniu usług mogą być skorelowane z próbami manipulacji danymi lub błędami w dokumentacji.
- **Profil dostawcy:** Cechy związane z wolumenem roszczeń na dostawcę (`Monthly_claim_volume`) pozwalają modelowi na identyfikację anomalii w skali działalności danej placówki medycznej.

7 Podsumowanie i wnioski

Niniejsze badanie pozwoliło na opracowanie i weryfikację modelu uczenia maszynowego opartego na algorytmie XGBoost, dedykowanego detekcji nadużyć w roszczeniach medycznych. Wyniki potwierdziły wysoką skuteczność zaproponowanej metodyki.

7.1 Ocena poprawności i interpretacja rezultatów

Model finalny osiągnął bardzo wysoki poziom czułości ($Recall = 0.97$) przy zachowaniu precyzji na poziomie 0.82.

- **Poprawność merytoryczna:** Wysoka precyzja wskazuje, że model skutecznie odróżnia rzeczywiste oszustwa od błędów w dokumentacji czy nietypowych, ale uczciwych procedur.
- **Interpretacja:** Największy wpływ na decyzje modelu miały cechy finansowe (`Claim_Amount`) oraz czasowe (`Days_Between_Service_and_Claim`). Potwierdza to hipotezę, że anomalie w procesach rozliczeniowych są najsilniejszymi indykatorami oszustw w sektorze ochrony zdrowia.

7.2 Ograniczenia modelu

Mimo satysfakcjonujących wyników, zidentyfikowano pewne ograniczenia:

- **Skala danych:** Zbiór 10 000 rekordów, choć reprezentatywny, nie oddaje pełnej złożoności globalnych systemów medycznych, gdzie zmienność procedur jest znacznie większa.
- **Charakter oszustw:** Model wykrywa wzorce obecne w danych historycznych. Oszustwa typu „nowego” (*zero-day fraud*) mogą początkowo pozostawać niewykryte do czasu aktualizacji bazy treningowej.
- **Brak danych kontekstowych:** Model nie posiada informacji o powiązaniach personalnych między lekarzami a pacjentami, co mogłoby jeszcze bardziej podnieść precyzję detekcji.

7.3 Dalsze kierunki rozwoju

W celu dalszej optymalizacji systemu sugeruje się:

1. **Analizę grafową:** Wprowadzenie cech opisujących relacje w sieci dostawca-pacjent w celu wykrywania zorganizowanych grup wyłudających świadczenia.
2. **Modelowanie online:** Wdrożenie systemu uczącego się w czasie rzeczywistym, co pozwoliłoby na błyskawiczną reakcję na zmieniające się techniki oszustów.
3. **Wyjaśnialność modelu (XAI):** Zastosowanie wartości SHAP (*SHapley Additive exPlanations*), aby dostarczyć analitykom ds. nadużyć szczegółowe, tekstowe uzasadnienie dla każdego oflagowanego roszczenia. Wykres ważności cech pozwala na zrozumienie, które cechy mają największy wpływ na decyzje modelu, SHAP pozwala na wyjaśnienie decyzji modelu dla każdego pacjenta.

7.4 Konkluzja

Opracowany model XGBoost stanowi skuteczne narzędzie wspierające **zespoły weryfikacji roszczeń**. Dzięki obniżeniu progu decyzyjnego do 0.3, system minimalizuje ryzyko finansowe związane z niewykryciem nadużyć, stanowiąc solidny fundament pod budowę zautomatyzowanego systemu *Anti-Fraud*.

Literatura

- [1] Nudrat Abbas. Healthcare fraud detection dataset. <https://www.kaggle.com/datasets/nudratabbas/healthcare-fraud-detection-dataset>.
- [2] National Health Care Anti-Fraud Association. A global scoping review on the patterns of medical fraud and abuse: integrating data-driven detection, prevention, and legal responses. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11831774/>, 2025.