

Wykrywanie nadużyć w służbie zdrowia

Zofia Dekowska

18 maja 2026

Spis treści

1	Wstęp i identyfikacja problemu	3
1.1	Typ zadania Machine Learning	3
1.2	Specyfika problemu	3
1.3	Cel biznesowy i analityczny	3
2	Wybór i uzasadnienie zbioru danych	3
2.1	Charakterystyka źródła danych	3
2.2	Struktura i opis cech zbioru	3
2.3	Uzasadnienie wyboru zbioru	4
3	Wybór i uzasadnienie miar jakości	4
3.1	Uzasadnienie biznesowe progu decyzyjnego	5
4	Wybór algorytmu	5
5	Inżynieria cech i przygotowanie danych	6
5.1	Strategia podziału danych (Time-based Split)	6
5.2	Czyszczenie danych i obsługa brakujących wartości	6
5.3	Usuwanie zmiennych powodujących wyciek danych	7
5.4	Bezpieczne kodowanie częstościowe (Frequency Encoding)	7
5.5	Kodowanie zmiennych kategorycznych o niskiej kardynalności	7
6	Dobór hiperparametrów i zapobieganie przeuczeniu	8
6.1	Definicja funkcji celu i kryterium optymalizacji	8
6.2	Przestrzeń poszukiwań hiperparametrów	8
6.3	Matematyczne mechanizmy zapobiegania przeuczeniu	8
6.4	Końcowe parametry modelu	10
7	Trening modelu i ocena wyników	10
7.1	Wyniki na zbiorze treningowym	11
7.2	Wyniki na zbiorze testowym	11
7.3	Macierz pomyłek	12
7.4	Analiza krzywej Precision-Recall	13
7.5	Analiza istotności cech	13
7.6	Porównanie z modelem bazowym Random Forest	14

8	Podsumowanie i wnioski	15
8.1	Ocena skuteczności modelu	15
8.2	Interpretacja wyników	16
8.3	Znaczenie zastosowanego podziału czasowego	16
8.4	Ograniczenia modelu	16
8.5	Możliwe kierunki dalszego rozwoju	17
8.6	Konkluzja	17

1 Wstęp i identyfikacja problemu

1.1 Typ zadania Machine Learning

Problem detekcji oszustw w roszczeniach medycznych został zdefiniowany jako zadanie klasyfikacji binarnej. Celem modelu jest przypisanie każdego roszczenia do jednej z dwóch rozłącznych klas:

- **Klasa 0 (Negative):** Roszczenie uczciwe, zgodne z procedurami.
- **Klasa 1 (Positive):** Roszczenie noszące znamiona oszustwa lub nadużycia.

1.2 Specyfika problemu

Kluczową cechą zidentyfikowanego zadania jest silne **niezbalansowanie zbioru danych**. W rzeczywistych systemach medycznych oszustwa stanowią niewielki odsetek wszystkich transakcji (w badanym zbiorze jest to ok. 8.3%).

Z punktu widzenia uczenia maszynowego, jest to trudniejsze zadanie od klasycznej klasyfikacji, ponieważ model mógłby ignorować klasę mniejszościową. W związku z tym, problem ten wymaga zastosowania specyficznych algorytmów oraz miar jakości skupionych na klasie pozytywnej.

1.3 Cel biznesowy i analityczny

Głównym celem jest stworzenie narzędzia wspomagającego analityków ds. nadużyć w służbie zdrowia. Priorytetem jest wysoka **czułość**, aby zminimalizować ryzyko finansowe związane z niewykrytymi oszustwami, przy jednoczesnym zachowaniu akceptowalnego poziomu **precyzji**, aby nie przeciążyć działu weryfikacji fałszywymi alarmami.

2 Wybór i uzasadnienie zbioru danych

2.1 Charakterystyka źródła danych

W badaniu wykorzystano zbiór danych *Healthcare Fraud Detection Dataset* pochodzący ze strony Kaggle [1]. Zbiór ten zawiera szczegółowe rekordy dotyczące roszczeń medycznych, obejmujące informacje o pacjentach, procedurach oraz podmiotach świadczących usługi. Dane te odzwierciedlają rzeczywiste scenariusze operacyjne w systemach ubezpieczeń zdrowotnych, co czyni je reprezentatywnym materiałem do budowy systemów typu *fraud detection*.

2.2 Struktura i opis cech zbioru

Wykorzystany zbiór danych charakteryzuje się dużą wielowymiarowością, co pozwala na wieloaspektową analizę zachowań o charakterze oszukańczym. Cechy zostały pogrupowane w pięć kluczowych kategorii:

- **Informacje finansowe i roszczeniowe:** Kluczowe zmienne numeryczne *Claim_Amount* oraz *Approved_Amount*. Dodatkowo uwzględniono status roszczenia (*approved*, *rejected*, *pending*) oraz typ ubezpieczenia (*private*, *Medicare*, *Medicaid*, *self-pay*).

- **Dane o pacjencie:** Profil demograficzny (wiek, płeć, lokalizacja na poziomie stanu) wzbogacony o historię medyczną, w tym wskaźnik chorób przewlekłych (*chronic condition indicator*) oraz liczbę wizyt w ciągu ostatnich 12 miesięcy. Pozwala to modelowi na identyfikację pacjentów o nietypowej aktywności.
- **Dane o dostawcach usług:** Unikalne identyfikatory oraz specjalizacje (np. kardiologia, ortopedia). Istotną cechą jest miesięczny wolumen roszczeń (*Monthly claim volume*), który pozwala wykrywać nienaturalnie wysoką aktywność rozliczeniową w stosunku do średniej.
- **Kodowanie medyczne:** Zastosowanie standardów ICD-10 (diagnozy) oraz CPT (procedury). Zbiór uwzględnia logiczne powiązania między postawioną diagnozą a wykonaną procedurą, co jest fundamentem wykrywania zawyżania kodu procedury medycznej.
- **Atrybuty czasowe i logistyczne:** Cechy określające czas między wykonaniem usługi a złożeniem wniosku (*Days_Between_Service_and_Claim*), typ wizyty (*outpatient, inpatient, emergency*) oraz długość hospitalizacji (*Length of stay*).

2.3 Uzasadnienie wyboru zbioru

Wybór tego konkretnego zbioru danych podyktowany był następującymi czynnikami:

1. **Realizm problemu:** Dane zawierają naturalnie występujące braki (*missing values*) oraz wymagają zaawansowanego preprocessingu (np. kodowanie cech tekstowych), co pozwala na weryfikację modelu w warunkach zbliżonych do rzeczywistych.
2. **Niezbalansowanie klas:** Według szacunków NHCAA [2], nadużycia generują straty na poziomie od 3% do nawet 10% całkowitego budżetu ochrony zdrowia, co czyni udział 8% w badanym zbiorze danymi wysoce reprezentatywnymi.
3. **Złożoność relacji:** Dane pozwalają na analizę nie tylko prostych kwot, ale również zależności między pacjentem, typem procedury a zachowaniem dostawcy usług.

3 Wybór i uzasadnienie miar jakości

W problematyce detekcji oszustw medycznych dobór metryk jest determinowany przez silne niezbalansowanie klas oraz asymetrię kosztów błędów. Ze względu na to, że klasa pozytywna (oszustwa) stanowi jedynie ok. 8% zbioru, standardowa miara *dokładność* (accuracy) jest niewystarczająca – model klasyfikujący wszystkie przypadki jako uczciwe, osiągnąłby wysoką dokładność, będąc całkowicie bezużytecznym z biznesowego punktu widzenia.

W związku z powyższym, do oceny modelu wybrano zestaw metryk skupionych na zdolnościach dyskryminacyjnych algorytmu względem klasy mniejszościowej:

- **Czułość (Recall):** Jest to priorytetowa metryka w tym badaniu. Określa ona zdolność modelu do wykrywania faktycznych oszustw. Wysoka czułość oznacza, że system minimalizuje liczbę błędów II rodzaju (*False Negatives*), czyli sytuacji, w których nadużycie finansowe pozostaje niewykryte przez system kontroli.

- **Precyzja (Precision):** Informuje o tym, jaka część wskazań modelu jako oszustwo faktycznie nimi była. Wysoka precyzja pozwala ograniczyć liczbę błędów I rodzaju (*False Positives*), co przekłada się na mniejszą liczbę bezpodstawnych dochodzeń i optymalizację czasu pracy analityków weryfikujących zgłoszenia.
- **F1-Score:** Jako średnia harmoniczna precyzji i czułości, stanowi syntetyczny wskaźnik balansu modelu. Jest to miara szczególnie użyteczna przy porównywaniu różnych algorytmów (np. Random Forest vs XGBoost).
- **Krzywa Precision-Recall (PRC) oraz Area Under PRC (AUPRC):** Wybrano tę miarę zamiast standardowej krzywej ROC, ponieważ AUPRC lepiej odzwierciedla skuteczność klasyfikatora w warunkach dużej dysproporcji klas, kładąc większy nacisk na wydajność modelu w obszarze klasy pozytywnej.

Ze względu na niebalansowany charakter danych metryka dokładność (accuracy) nie stanowiła głównego kryterium oceny jakości modelu, ponieważ mogłaby prowadzić do zawyżonej oceny skuteczności poprzez preferowanie klasy większościowej.

3.1 Uzasadnienie biznesowe progu decyzyjnego

W analizie przyjęto założenie, że koszt niewykrytego oszustwa (strata finansowa ubezpieczyciela) jest znacznie wyższy niż koszt błędnej weryfikacji uczciwego roszczenia (koszt pracy analityka). W związku z tym, w ostatecznej implementacji modelu XGBoost, zdecydowano się na obniżenie progu decyzyjnego (*threshold*) do poziomu **0.3**, co pozwoliło na maksymalizację czułości (*Recall*) przy zachowaniu akceptowalnego poziomu precyzji.

4 Wybór algorytmu

Do realizacji zadania detekcji nadużyć medycznych wybrano algorytm **XGBoost** (*Extreme Gradient Boosting*), należący do grupy metod *gradient boosting* opartych na zespołach drzew decyzyjnych.

Wybór ten był uzasadniony kilkoma kluczowymi właściwościami algorytmu:

1. **Wysoka skuteczność dla danych tabelarycznych:** XGBoost należy do najskuteczniejszych algorytmów dla danych strukturalnych i regularnie osiąga dobre wyniki w problemach klasyfikacyjnych związanych z fraud detection.
2. **Odporność na nieliniowości:** Algorytm potrafi modelować złożone, nieliniowe zależności pomiędzy cechami, które często występują w danych medycznych i finansowych.
3. **Wbudowane mechanizmy regularyzacji:** XGBoost posiada natywne wsparcie dla regularyzacji L1 i L2, co pozwala skutecznie ograniczać zjawisko przeuczenia.
4. **Obsługa niebalansowanych danych:** Parametr `scale_pos_weight` umożliwia zwiększenie znaczenia klasy mniejszościowej (fraudów) podczas procesu uczenia.
5. **Obsługa brakujących danych i cech mieszanych:** Algorytm dobrze radzi sobie zarówno z cechami numerycznymi, jak i zakodowanymi zmiennymi kategorycznymi.

6. **Interpretowalność:** Możliwość analizy ważności cech (*feature importance*) pozwala lepiej zrozumieć czynniki wpływające na decyzje modelu.

Dodatkową zaletą XGBoost jest wysoka efektywność obliczeniowa oraz możliwość zastosowania mechanizmu *early stopping*, co pozwoliło na efektywną kontrolę procesu uczenia i ograniczenie przeuczenia modelu.

5 Inżynieria cech i przygotowanie danych

Aby zapewnić jak najwyższą dokładność modelu i odwzorować realne warunki, w jakich będzie on działał na produkcji, odpowiednio przebudowano proces przygotowania danych. Kluczowym założeniem nowego potoku przetwarzania (*data pipeline*) było całkowite odseparowanie od siebie zbiorów danych oraz wyeliminowanie zjawiska wycieku informacji (*data leakage*).

5.1 Strategia podziału danych (Time-based Split)

W miejsce standardowego, losowego podziału danych zastosowano podejście oparte na kryterium chronologicznym (*time-based train-test split*). W problemach temporalnych klasyczny random cross-validation prowadziłby do przecieku informacji pomiędzy okresami czasowymi. W systemach detekcji nadużyć finansowych i medycznych charakterystyka oszustw ulega ciągłym zmianom w czasie. Testowanie modelu na danych z tego samego okresu, z którego pochodzą dane treningowe, prowadzi do nierealistycznie zawyżonych metryk. Takie podejście wierniej odzwierciedla rzeczywisty scenariusz produkcyjny, w którym model predykcyjny jest trenowany na danych historycznych i wykorzystywany do oceny przyszłych roszczeń.

Dane zostały podzielone według kolumny `Claim_Submission_Year` na trzy niezależne zbiory:

- **Zbiór treningowy (`X_train`):** Obejmuje rekordy z lat **2021-2022**. Służy do bezpośredniej nauki algorytmu oraz wyliczania statystyk.
- **Zbiór walidacyjny (`X_val`):** Obejmuje rekordy z roku **2023**. Wykorzystywany przez bibliotekę Optuna do optymalizacji hiperparametrów oraz jako kryterium wczesnego zatrzymania (*early stopping*), chroniąc model przed przeuczeniem.
- **Zbiór testowy (`X_test`):** Obejmuje rekordy z roku **2024**. Stanowi całkowicie odizolowany zbiór (*hold-out set*), służący do ostatecznej oceny skuteczności biznesowej.

5.2 Czyszczenie danych i obsługa brakujących wartości

Procedura obsługi braków danych (NaN) została zróżnicowana w zależności od typu zmiennej, aby zachować maksimum informacji:

1. **Zmienne numeryczne:** Brakujące wartości numeryczne zostały uzupełnione medianą danej cechy. Mediana została wybrana zamiast wartości 0, ponieważ jest bardziej odporna na wartości odstające oraz nie wprowadza sztucznego znaczenia numerycznego.

2. **Zmienne kategoryczne:** Braki w zmiennych tekstowych zostały uzupełnione stałą wartością 'Unknown', tworząc nową, jawną kategorię dla klasyfikatora.

5.3 Usuwanie zmiennych powodujących wyciek danych

Ze zbioru usunięto zmienne zawierające informacje niedostępne w momencie predykcji lub bezpośrednio powiązane z końcową decyzją procesu obsługi roszczenia. Pozostawienie takich cech prowadziłoby do zjawiska wycieku danych (*target leakage*) oraz sztucznego zawyżenia skuteczności modelu.

1. **Claim_Status:** Zmienna opisuje końcowy status roszczenia (np. zaakceptowane, odrzucone, w trakcie analizy). Informacja ta jest znana dopiero po zakończeniu procesu weryfikacji i może bezpośrednio ujawniać wynik klasyfikacji fraudowej.
2. **Approved_Amount:** Kwota zatwierdzona do wypłaty jest ustalana po przeprowadzeniu procesu oceny roszczenia. W praktyce może być silnie skorelowana z decyzją dotyczącą wykrycia oszustwa, dlatego jej wykorzystanie prowadziłoby do nieuczciwego uprzywilejowania modelu.
3. **Number_of_Claims_Per_Provider_Monthly:** Zmienna agregowana na poziomie miesięcznym może zawierać informacje pochodzące z przyszłych obserwacji względem analizowanego roszczenia. Powodowałoby to przeciek informacji temporalnej oraz nierealistyczne zawyżenie jakości predykcji.

5.4 Bezpieczne kodowanie częstościowe (Frequency Encoding)

Zmienne wysokiej kardynalności (*high-cardinality features*), takie jak `Provider_ID`, `Diagnosis_Code` oraz `Procedure_Code`, posiadają setki lub tysiące unikalnych wartości. Zastosowanie dla nich tradycyjnego kodowania *One-Hot Encoding* doprowadziłoby do znaczącego wzrostu wymiarowości przestrzeni cech oraz pogorszenia efektywności procesu uczenia..

Zamiast tego wdrożono **Frequency Encoding** (kodowanie częstościowe). Każda unikalna wartość tekstowa jest zastępowana jej względną częstością występowania w danych. Aby zapobiec *data leakage*, cały proces zaprojektowano następująco:

$$P(c) = \frac{\text{Count}(c \in X_{\text{train}})}{\text{Total Rows in } X_{\text{train}}} \quad (1)$$

Mapowanie częstości (*Frequency Map*) jest generowane **wyłącznie na podstawie zbioru treningowego**. Następnie te same wartości mapowane są na zbiór walidacyjny oraz testowy. W przypadku pojawienia się w zbiorze testowym nowej wartości kody (np. nowego lekarza lub rzadkiej procedury, która nie wystąpiła w latach 2021–2022), brak mapowania jest bezpiecznie zastępowany wartością 0, co uodparnia model na nieznane wcześniej podmioty.

5.5 Kodowanie zmiennych kategorycznych o niskiej kardynalności

Dla pozostałych zmiennych kategorycznych (`Patient_Gender`, `Insurance_Type`, `Provider_Specialty`, `Patient_State`, `Visit_Type`) zastosowano technikę *One-Hot Encoding*.

Aby zapewnić pełną spójność wymiarową macierzy wejściowych do algorytmu XGBoost, po dokonaniu transformacji na każdym ze zbiorów osobno, zbiory walidacyjny oraz testowy są wyrównywane (*reindex*) do struktury kolumn zbioru treningowego. Ewentualne brakujące kolumny katagoryczne w zbiorach testowych są automatycznie uzupełniane zerami.

6 Dobór hiperparametrów i zapobieganie przeuczeniu

W celu zmaksymalizowania zdolności generalizacji modelu XGBoost oraz precyzyjnego dostrojenia jego parametrów strukturalnych, wdrożono zaawansowany proces automatycznego przeszukiwania przestrzeni hiperparametrów przy użyciu frameworku **Optuna**. Tradycyjne metody, takie jak *Grid Search*, charakteryzują się niską efektywnością obliczeniową. Optuna wykorzystuje algorytm Tree-structured Parzen Estimator (TPE), czyli bayesowską metodę optymalizacji hiperparametrów, która dynamicznie uczy się na podstawie wyników poprzednich iteracji.

6.1 Definicja funkcji celu i kryterium optymalizacji

Proces optymalizacji został zaprojektowany z uwzględnieniem specyfiki silnie niebalansowanego zbioru danych medycznych. Jako funkcję celu wybrano maksymalizację metryki **F1-score** dla klasy mniejszościowej (oszustwa, `Is_Fraud = 1`), wyliczanej na odizolowanym zbiorze walidacyjnym (`X_val`).

Aby zwiększyć czułość modelu na przypadki fraudowe oraz ograniczyć liczbę fałszywie negatywnych predykcji. Próg decyzyjny równy 0.3 został dobrany wyłącznie na podstawie wyników uzyskanych na zbiorze walidacyjnym (`X_val`). Zbiór testowy (`X_test`) pozostawał całkowicie odizolowany aż do końcowej ewaluacji modelu. Pozwoliło to uniknąć dopasowania progu decyzyjnego do danych testowych oraz zachować wiarygodność końcowych metryk generalizacji.

Próbkowanie prawdopodobieństw realizowano za pomocą metody `predict_proba`, co pozwoliło Optunie na poszukiwanie struktury drzew idealnie dopasowanej do zadanego progu operacyjnego. Przeprowadzono łącznie $n = 50$ niezależnych eksperymentów (*trials*).

6.2 Przestrzeń poszukiwań hiperparametrów

Zdefiniowana przestrzeń poszukiwań obejmowała zarówno parametry odpowiedzialne za pojemność modelu, balansowanie klas, losowość procesu uczenia, jak i zaawansowaną regularyzację matematyczną:

6.3 Matematyczne mechanizmy zapobiegania przeuczeniu

W celu ograniczenia zjawiska przeuczenia (*overfittingu*), które we wcześniejszych iteracjach projektu prowadziło do nierealistycznie wysokich wyników na zbiorze treningowym, zastosowano kilka mechanizmów ograniczających przeuczenie modelu:

1. **Wczesne zatrzymanie (Early Stopping):** Zarówno podczas optymalizacji hiperparametrów, jak i końcowego treningu modelu zastosowano mechanizm `early_stopping_rounds = 30`. Proces budowy kolejnych drzew był

Tabela 1: Przestrzeń poszukiwań hiperparametrów w algorytmie Optuna

Hiperparametr	Zakres próbkowania	Rola w modelu
max_depth	4 – 10 (int)	Maksymalna głębokość pojedynczego drzewa decyzyjnego.
learning_rate	0.01 – 0.3 (float)	Tempo uczenia modelu.
subsample	0.5 – 1.0 (float)	Ułamek rekordów losowany do budowy każdego drzewa.
colsample_bytree	0.5 – 1.0 (float)	Losowanie podzbioru cech dla każdego drzewa w celu zwiększenia różnorodności modelu.
scale_pos_weight	1.0 – 15.0 (float)	Zwiększenie znaczenia klasy mniejszościowej (fraudów) podczas optymalizacji.
min_child_weight	1 – 5 (int)	Minimalna suma wag obserwacji wymagana do utworzenia nowego liścia.
gamma	0 – 5 (float)	Minimalny spadek funkcji kosztu wymagany do wykonania kolejnego podziału drzewa.
lambda (λ)	10^{-3} – 10.0 (log)	Regularyzacja L2 ograniczająca nadmierne wartości wag liści.
alpha (α)	10^{-3} – 10.0 (log)	Regularyzacja L1 promująca rzadsze i prostsze modele.

automatycznie przerywany, jeśli wartość funkcji straty *logloss* obliczana na zbiorze walidacyjnym (`x_val`) nie poprawiała się przez 30 kolejnych iteracji. Pozwoliło to ograniczyć nadmierne dopasowanie modelu do danych treningowych.

2. **Regularyzacja L1 i L2:** Parametry `alpha` oraz `lambda` rozszerzają funkcję kosztu XGBoost o człony karzące za nadmierną złożoność modelu:

$$\mathcal{L}^{(t)} = \sum_i l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) \quad (2)$$

gdzie człon regularyzacyjny przyjmuje postać:

$$\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 + \alpha \sum_{j=1}^T |w_j| \quad (3)$$

Regularyzacja L2 ogranicza nadmierne wartości wag liści, natomiast regularyzacja L1 promuje prostsze i bardziej odporne struktury drzew.

3. **Losowość procesu uczenia:** Parametry `subsample` oraz `colsample_bytree` wprowadzają kontrolowaną losowość poprzez próbkowanie rekordów oraz cech wykorzystywanych do budowy drzew. Mechanizm ten ogranicza korelację pomiędzy drzewami i poprawia zdolność generalizacji modelu.
4. **Ograniczenie złożoności strukturalnej:** Parametry `max_depth`, `min_child_weight` oraz `gamma` kontrolują złożoność pojedynczych drzew

decyzyjnych. Ograniczenie głębokości drzew, wymuszenie minimalnej liczby obserwacji w liściach oraz kontrola jakości kolejnych podziałów zmniejszają ryzyko modelowania szumu obecnego w danych treningowych.

6.4 Końcowe parametry modelu

Po przeprowadzeniu procesu optymalizacji z wykorzystaniem biblioteki Optuna wybrano konfigurację hiperparametrów osiągającą najwyższą wartość metryki F1-score na zbiorze walidacyjnym. Najlepszy rezultat uzyskano w próbie (*trial*) nr 41, dla której:

$$F1_{val} = 0.673 \quad (4)$$

Finalna konfiguracja modelu XGBoost została przedstawiona w tabeli 2.

Tabela 2: Końcowe hiperparametry modelu XGBoost

Hiperparametr	Wartość
max_depth	4
learning_rate	0.2302
subsample	0.7681
scale_pos_weight	1.0059
lambda	0.0044
alpha	1.0331
colsample_bytree	0.9091
min_child_weight	2
gamma	1.3248

Uzyskana konfiguracja wskazuje, że najlepsze rezultaty osiągnięto dla relatywnie płytkich drzew decyzyjnych ($\text{max_depth} = 4$), co ograniczyło ryzyko przeuczenia. Jednocześnie zastosowanie parametru `gamma` oraz regularyzacji L1 (`alpha`) dodatkowo wymuszało tworzenie bardziej konserwatywnych i odpornych struktur decyzyjnych.

Wysoka wartość parametru `colsample_bytree` sugeruje, że model korzystał z dużej części dostępnych cech przy budowie drzew, natomiast umiarkowana wartość `subsample` wprowadzała dodatkową losowość zwiększającą zdolność generalizacji.

Interesującą obserwacją jest fakt, że Optuna wybrała wartość parametru `scale_pos_weight` bliską 1.0, mimo występowania nierównowagi klas. Sugeruje to, że zastosowane techniki inżynierii cech, obniżenie progu decyzyjnego oraz odpowiednia regularyzacja okazały się wystarczające do skutecznego wykrywania klasy fraudowej bez konieczności silnego sztucznego ważenia przykładów pozytywnych. Zbyt agresywne zwiększanie wagi klasy mniejszościowej prowadziło w eksperymentach do nadmiernej liczby fałszywych alarmów oraz pogorszenia zdolności generalizacji modelu.

7 Trening modelu i ocena wyników

Po zakończeniu procesu optymalizacji hiperparametrów przeprowadzono finalny trening modelu **XGBoost** na zbiorze treningowym obejmującym dane z lat 2021-2022. Proces uczenia realizowano z wykorzystaniem najlepszego zestawu hiperparametrów znalezionych przez framework Optuna oraz z zastosowaniem mechanizmu *early stopping*, monitorującego wartość funkcji straty *logloss* na zbiorze walidacyjnym z roku 2023.

Końcowa predykcja klasy fraudowej była generowana na podstawie prawdopodobieństw zwracanych przez metodę `predict_proba`. Ze względu na charakter problemu detekcji oszustw zastosowano obniżony próg decyzyjny równy **0.3**, zgodnie z zależnością:

$$\hat{y} = \begin{cases} 1 & \text{dla } P(y = 1|X) \geq 0.3 \\ 0 & \text{dla } P(y = 1|X) < 0.3 \end{cases} \quad (5)$$

Obniżenie progu decyzyjnego pozwoliło zwiększyć czułość modelu na przypadki fraudowe kosztem większej liczby fałszywych alarmów, co stanowi akceptowalny kompromis w systemach wykrywania nadużyć finansowych i medycznych.

7.1 Wyniki na zbiorze treningowym

Model osiągnął wysoką skuteczność na zbiorze treningowym:

- **Accuracy:** 97%
- **Precision dla klasy fraudowej:** 0.78
- **Recall dla klasy fraudowej:** 0.92
- **F1-score dla klasy fraudowej:** 0.84

Wysoka wartość recall oznacza, że model był zdolny do wykrycia zdecydowanej większości przypadków oszustw obecnych w danych treningowych. Jednocześnie brak perfekcyjnych wyników ($F1 < 1.0$) sugeruje, że zastosowane mechanizmy regularyzacji skutecznie ograniczyły zjawisko przeuczenia.

7.2 Wyniki na zbiorze testowym


Kluczowym etapem ewaluacji była ocena modelu na całkowicie odizolowanym zbiorze testowym obejmującym dane z roku 2024. Uzyskano następujące wyniki:

- **Accuracy:** 94%
- **Precision dla klasy fraudowej:** 0.60
- **Recall dla klasy fraudowej:** 0.62
- **F1-score dla klasy fraudowej:** 0.61

Spadek jakości względem zbioru treningowego był oczekiwany i wynika z naturalnego zjawiska zmiany rozkładu danych w czasie (*concept drift*) oraz obecności nowych schematów fraudowych w roku 2024. Pomimo tego model zachował stabilną zdolność generalizacji i utrzymał relatywnie zbalansowane wartości precision oraz recall.

7.3 Macierz pomyłek

Analiza macierzy pomyłek pozwoliła dokładniej ocenić charakter błędów modelu.




Rysunek 1: Macierz pomyłek.

Na zbiorze testowym model:

- poprawnie sklasyfikował **2160** legalnych roszczeń,
- poprawnie wykrył **121** przypadków fraudowych,
- wygenerował **82** fałszywe alarmy (*false positives*),
- nie wykrył **73** rzeczywistych fraudów (*false negatives*).

W kontekście biznesowym większy koszt operacyjny wiąże się zazwyczaj z niewykryciem oszustwa niż z wygenerowaniem dodatkowego alarmu do ręcznej weryfikacji. Z tego względu przyjęty próg decyzyjny oraz uzyskany poziom recall można uznać za racjonalny kompromis pomiędzy skutecznością detekcji a liczbą błędnych alarmów.

7.4 Analiza krzywej Precision-Recall




Rysunek 2: Krzywa Precision-Recall.

Dodatkowej oceny jakości modelu dokonano za pomocą krzywej Precision-Recall. Uzyskana wartość **Average Precision (AP) = 0.72** wskazuje, że model zachowuje dobrą zdolność separacji klasy fraudowej od legalnych roszczeń nawet przy zmieniających się progach klasyfikacyjnych.

Krzywa Precision-Recall jest szczególnie użyteczna w problemach silnie niezbalansowanych, ponieważ koncentruje się wyłącznie na jakości predykcji klasy pozytywnej i nie jest sztucznie zawyżana przez dominującą klasę negatywną.

7.5 Analiza istotności cech

W celu zwiększenia interpretowalności modelu przeprowadzono analizę istotności cech (*feature importance*).



Rysunek 3: Ranking najważniejszych cech modelu.

Największy wpływ na decyzje modelu miały:

- Claim_Amount,
- Patient_Age,
- Days_Between_Service_and_Claim,
- Provider_ID_freq,
- Length_of_Stay.

Wyniki te są zgodne z intuicją biznesową. Nietypowo wysokie kwoty roszczeń, podejrzone opóźnienia pomiędzy wykonaniem usługi a zgłoszeniem roszczenia, a także nietypowa aktywność konkretnych dostawców usług medycznych mogą stanowić istotne sygnały fraudowe.

7.6 Porównanie z modelem bazowym Random Forest

W celu zweryfikowania zasadności zastosowania algorytmu XGBoost przeprowadzono dodatkowy eksperyment z wykorzystaniem modelu Random Forest jako modelu bazowego (*baseline model*).

Model Random Forest został wytrenowany na identycznym pipeline preprocessingowym oraz tym samym podziale czasowym danych. Zastosowano również identyczny próg decyzyjny wynoszący 0.3, co zapewniło porównywalność wyników.

Na zbiorze testowym model Random Forest osiągnął:

- **Recall = 1.00** dla klasy fraudowej,
- **Precision = 0.35**,
- **F1-score = 0.52**.

Oznacza to, że model wykrywał praktycznie wszystkie przypadki oszustw, jednak generował dużą liczbę fałszywych alarmów (*false positives*). Macierz pomyłek wykazała aż 365 błędnie oznaczonych legalnych roszczeń.

W porównaniu do Random Forest, końcowy model XGBoost osiągnął znacznie lepszy kompromis pomiędzy precision i recall:

- **Precision = 0.60**,
- **Recall = 0.62**,
- **F1-score = 0.61**.

Pomimo niższego recall niż Random Forest, model XGBoost znacząco ograniczył liczbę fałszywych alarmów, co ma kluczowe znaczenie biznesowe w systemach wspierających analityków fraudowych. Nadmierna liczba błędnych zgłoszeń mogłaby prowadzić do przeciążenia zespołów kontrolnych oraz wzrostu kosztów operacyjnych.

Dodatkowo analiza ważności cech wykazała, że Random Forest nadmiernie koncentrował się na pojedynczej zmiennej `Days_Between_Service_and_Claim`, podczas gdy XGBoost wykorzystywał bardziej zrównoważony zestaw cech. Sugeruje to lepszą zdolność generalizacji modelu boostingowego.

8 Podsumowanie i wnioski

Celem projektu było opracowanie modelu uczenia maszynowego zdolnego do wykrywania potencjalnych nadużyć w roszczeniach medycznych (*healthcare fraud detection*) z wykorzystaniem algorytmu XGBoost. Szczególny nacisk położono na eliminację wycieku danych (*data leakage*), realistyczny podział czasowy danych oraz odpowiednie balansowanie jakości detekcji klasy mniejszościowej.

8.1 Ocena skuteczności modelu

Finalny model osiągnął na zbiorze testowym następujące wyniki dla klasy fraudowej (`Is_Fraud = 1`):

- **Precision:** 0.60
- **Recall:** 0.62
- **F1-score:** 0.61

Uzyskane rezultaty należy uznać za satysfakcjonujące, szczególnie biorąc pod uwagę:

1. silną nierównowagę klas,
2. realistyczny podział czasowy danych,
3. brak wycieku informacji pomiędzy zbiorem treningowym i testowym.

Model zachował również wysoką skuteczność dla klasy większościowej (uczciwe roszczenia), osiągając dokładność ogólną (*accuracy*) na poziomie 94%.

8.2 Interpretacja wyników

Analiza ważności cech wykazała, że największy wpływ na decyzje modelu miały:

- `Claim_Amount`,
- `Patient_Age`,
- `Days_Between_Service_and_Claim`,
- `Provider_ID_freq`.

Wskazuje to, że anomalie finansowe oraz nietypowe zachowania czasowe stanowią jedno z najważniejszych sygnałów fraudowych. Znaczenie zmiennej `Provider_ID_freq` sugeruje również, że częstość występowania określonych dostawców usług medycznych może być istotnym czynnikiem ryzyka.

Krzywa Precision-Recall potwierdziła, że model zachowuje relatywnie stabilny kompromis pomiędzy czułością a precyzją nawet przy niższych progach decyzyjnych.

8.3 Znaczenie zastosowanego podziału czasowego

Jednym z najważniejszych elementów projektu było zastosowanie podziału danych według lat (*time-based split*). W przeciwieństwie do klasycznego losowego podziału danych, takie podejście lepiej odzwierciedla rzeczywiste warunki wdrożenia systemów antyfraudowych.

Uzyskane metryki są niższe niż w początkowych eksperymentach opartych na losowym podziale danych, jednak należy je uznać za znacznie bardziej wiarygodne. Model został zmuszony do wykrywania fraudów występujących w przyszłych okresach czasowych, a nie jedynie do zapamiętywania wzorców obecnych w tych samych latach.

8.4 Ograniczenia modelu

Pomimo uzyskania dobrych rezultatów, model posiada kilka istotnych ograniczeń:

- zbiór danych obejmuje ograniczoną liczbę rekordów oraz relatywnie niewielką liczbę przypadków fraudowych,
- model opiera się wyłącznie na danych tabelarycznych i nie uwzględnia relacji sieciowych pomiędzy pacjentami i świadczeniodawcami,
- nowe typy oszustw (*zero-day fraud*) mogą nie zostać wykryte bez okresowego ponownego trenowania modelu.

8.5 Możliwe kierunki dalszego rozwoju

W przyszłości projekt mógłby zostać rozszerzony o:

1. analizę grafową relacji pacjent-świadczeniodawca,
2. wykorzystanie metod Explainable AI, takich jak SHAP,
3. dynamiczne dostrajanie progu decyzyjnego zależnie od kosztów biznesowych,
4. uczenie przyrostowe (*online learning*) pozwalające na adaptację do nowych schematów fraudowych.

8.6 Konkluzja

Opracowany model XGBoost stanowi skuteczne narzędzie wspierające proces automatycznej identyfikacji podejrzanych roszczeń medycznych. Zastosowanie realistycznego podziału czasowego danych, eliminacji wycieku informacji oraz odpowiedniej regularyzacji pozwoliło uzyskać model o dobrej zdolności generalizacji i praktycznej użyteczności w systemach wspomagania decyzji antyfraudowych.

Literatura

- [1] Nudrat Abbas. Healthcare fraud detection dataset. <https://www.kaggle.com/datasets/nudratabbas/healthcare-fraud-detection-dataset>.
- [2] National Health Care Anti-Fraud Association. A global scoping review on the patterns of medical fraud and abuse: integrating data-driven detection, prevention, and legal responses. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11831774/>, 2025.